

统计整理

杨弘毅

创建：2020 年 4 月 9 日
修改：2021 年 10 月 18 日

目录

1	TODO	2
2	基础	2
2.1	期望	2
2.2	方差	3
2.3	协方差	3
2.4	相关系数	4
3	矩	4
3.1	理解	4
3.2	定义	5
3.3	分类	6
3.4	矩母函数	8
3.4.1	定义	8
3.4.2	性质	9
4	假设检验 (Statistical hypothesis testing)	10
5	Chi-square distribution	11
6	Probability vs Likelihood	11
6.1	Probability	11
6.2	Likelihood	12
6.3	Maximum likelihood	12

1 TODO

- 参数与非参数方法
- conditional probability projection
- likelihood, log-likelihood, goodness-of-fit, quasi-maximum likelihood, ratio test
- Chi-square, joint hypothesis
- Newey West 1987
- Durbin Watson

2 基础

2.1 期望

对于随机变量 X ，其概率空间为 (Ω, \mathcal{F}, P) ，期望值 $\mathbb{E}[X]$ ，应有：

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) dP(\omega)$$

在离散以及连续情形下有如下定义，其中 $f(x)$ 为变量 X 的概率密度函数（PDF）。

$$\begin{aligned}\mathbb{E}[X] &= \sum_{i=1}^n x_i p_i = x_1 p_1 + x_2 p_2 + \cdots + x_n p_n \\ \mathbb{E}[X] &= \int x f(x) dx\end{aligned}$$

其性质有：

$$\begin{aligned}\mathbb{E}[X + Y] &= \mathbb{E}[X] + \mathbb{E}[Y] \\ \mathbb{E}[aX] &= a\mathbb{E}[X] \\ \mathbb{E}[XY] &= \mathbb{E}[X]\mathbb{E}[Y] \quad (X, Y \text{ are independent})\end{aligned}$$

2.2 方差

对于方差 (Variance), 定义有:

$$\begin{aligned}
 \text{Var}(X) &= \text{Cov}(X, X) = \sigma_X^2 \\
 &= \mathbb{E}[(X - \mathbb{E}[X])^2] \\
 &= \mathbb{E}[X^2 - 2X\mathbb{E}[X] + \mathbb{E}[X]^2] \\
 &= \mathbb{E}[X^2] - 2\mathbb{E}[X]^2 + \mathbb{E}[X]^2 \\
 &= \mathbb{E}[X^2] - \mathbb{E}[X]^2
 \end{aligned}$$

其性质有:

$$\begin{aligned}
 \text{Var}(X + a) &= \text{Var}(X) \\
 \text{Var}(aX) &= a^2 \text{Var}(X) \\
 \text{Var}(aX \pm bY) &= a^2 \text{Var}(X) + b^2 \text{Var}(Y) \pm 2ab \text{Cov}(X, Y) \\
 \text{Var}\left(\sum_{i=1}^N X_i\right) &= \sum_{i,j=1}^N \text{Cov}(X_i, X_j) = \sum_{i=1}^N \text{Var}(X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j) \\
 \text{Var}\left(\sum_{i=1}^N a_i X_i\right) &= \sum_{i,j=1}^N a_i a_j \text{Cov}(X_i, X_j) \\
 &= \sum_{i=1}^N a_i^2 \text{Var}(X_i) + \sum_{i \neq j} a_i a_j \text{Cov}(X_i, X_j) \\
 &= \sum_{i=1}^N a_i^2 \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq N} a_i a_j \text{Cov}(X_i, X_j)
 \end{aligned}$$

2.3 协方差

对于协方差 (Covariance) 其定义有:

$$\begin{aligned}
 \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))] \\
 &= \mathbb{E}[XY - X\mathbb{E}[Y] - Y\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y]] \\
 &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y] \\
 &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]
 \end{aligned}$$

性质有：

$$\text{Cov}(X, a) = 0$$

$$\text{Cov}(X, X) = \text{Var}(X)$$

$$\text{Cov}(X, Y) = \text{Cov}(Y, X)$$

$$\text{Cov}(aX, bY) = ab \text{Cov}(X, Y)$$

$$\text{Cov}(X + a, Y + b) = \text{Cov}(X, Y)$$

$$\text{Cov}(aX + bY, cW + dV) = ac \text{Cov}(X, W) + ad \text{Cov}(X, V) + bc \text{Cov}(Y, W) + bd \text{Cov}(Y, V)$$

2.4 相关系数

相关系数 (Correlation Coefficient)，为研究变量间线性相关程度的量。最早由统计学家卡尔·皮尔逊设计，也称为皮尔逊积矩相关系数 (Pearson product-moment correlation coefficient)，或皮尔逊相关系数：

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]}{\sigma_X \sigma_Y}$$

3 矩

3.1 理解

在物理学中，矩 (Moment) 源于阿基米德的杠杆原理，可简单认为是物理量与参照点距离的乘积，如力与力臂 (参考点的距离) 的乘积，得到的是力矩 (或扭矩)。如一杆“秤”，“秤”的平衡的两边重量与距离的乘积相同，则能保持平衡。

具体而言， n 阶矩 μ_n 为物理量 Q 与某参考点 x 的 n 次方的乘积，即 $\mu_n = x^n Q$ 。常见的物理量如力或电荷等，若物理量并非集中在单点上，矩就应该是在物理量在空间上的积分，因有： $\mu_u = \int x^n f(x) dr$ ，其中 $f(x)$ 为物理量的密度分布函数。

而物理中的矩与数学中的矩概念相通，而在概率论上，如一端秤砣重量为中奖金额 500 元，中奖概率为百分之一，即离中心点距离为 0.01，那么其期望应为 5 元。可以理解为了使得秤保持平衡，则另一端，在距离中心距离为 1，对应其秤砣重量中奖金额应为 5 元。

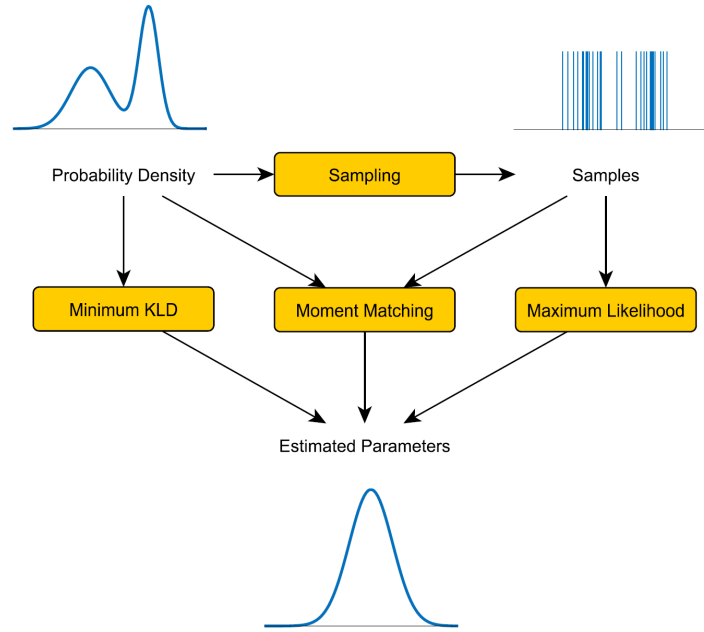


图 1: 矩匹配

3.2 定义

根据上述理解，物理学中与数学中的矩概念相通，即距离（概率）乘以物理量（随机变量）的大小。 p_i 为概率质量函数（Probability mass function, PMF），则对于 n 阶矩的离散形式有：

$$E[x^n] = \sum_i x_i^n p_i$$

在连续形式下， n 阶矩可以表示为 $(x - c)^n$ 的期望，其中 $f(x)$ 为概率密度函数（Probability density function, PDF），其中 c 为均值。当 c 为 0 时，即称为中心矩（Central moment）。相反，则称为非中心矩，或原始矩（Raw moment）：

$$E[x^n] = \mu_n = \int_{-\infty}^{\infty} (x - c)^n f(x) dx$$

除了根据 c 是否为零，根据是否进行标准化处理，可细分为标准矩。常用的矩有：

- 均值 $\text{Mean}(x) = \mathbb{E}(x)$ 为一阶非中心矩
- 方差 $\text{Variance}(x) = \mathbb{E}(x - \mu)^2$ 为二阶中心矩
- 偏度 $\text{Skewness}(x) = \frac{\mathbb{E}[(x - \mu)^3]}{\sigma^3}$ 为三阶标准矩
- 峰度 $\text{Kurtosis}(x) = \frac{\mathbb{E}[(x - \mu)^4]}{\sigma^4}$ 为四阶标准矩

3.3 分类

根据如上定义，从零阶至四阶的原始矩与中心矩有如下定义，其中定义 $\sigma = (\mathbb{E}[(x - \mu)^2])^{\frac{1}{2}}$ ：

阶	原始矩	中心矩	标准矩
0	$\mathbb{E}(x^0) = 1$	$\mathbb{E}[(x - \mu)^0] = 1$	$\frac{\mathbb{E}[(x - \mu)^0]}{\sigma^0} = 1$
1	$\mathbb{E}(x^1) = \mu$ (均值)	$\mathbb{E}[(x - \mu)^1] = 0$	$\frac{\mathbb{E}[(x - \mu)^1]}{\sigma^1} = 0$
2	$\mathbb{E}(x^2)$	$\mathbb{E}[(x - \mu)^2] = \sigma^2$ (方差)	$\frac{\mathbb{E}[(x - \mu)^2]}{\sigma^2} = 1$
3	$\mathbb{E}(x^3)$	$\mathbb{E}[(x - \mu)^3]$	$\frac{\mathbb{E}[(x - \mu)^3]}{\sigma^3}$ (偏度)
4	$\mathbb{E}(x^4)$	$\mathbb{E}[(x - \mu)^4]$	$\frac{\mathbb{E}[(x - \mu)^4]}{\sigma^4}$ (峰度)

原始矩 (Raw/crude moment)

当 $c = 0$ 时，称为原始矩。此时则有平均数 (mean) 或期望 (expected value) 的连续形式为：

$$\mu = E(x) = \int_{-\infty}^{\infty} (x - 0)^1 f(x) dx = \int_{-\infty}^{\infty} x f(x) dx$$

其离散形式为：

$$\mu = E(x) = \sum_i x_i p_i$$

中心矩 (Central moment)

期望值可以成为随机变量的中心，即当 $c = E(x)$ 时

$$\mu_n = E[(x - E(x))^n] = \int_{-\infty}^{\infty} (x - E(x))^n f(x) dx$$

同时可知任何变量的一阶中心矩为 0：

$$\begin{aligned}
 \mu_1 &= \int_{-\infty}^{\infty} (x - E(x))^1 f(x) dx \\
 &= \int_{-\infty}^{\infty} x f(x) dx - \int_{-\infty}^{\infty} E(x) f(x) dx \\
 &= E(x) - E(x) \int_{-\infty}^{\infty} f(x) dx \\
 &= E(x) - E(x) \times 1 = 0
 \end{aligned}$$

而二阶中心矩 (second central moment) 为**方差 (Variance)**

$$\begin{aligned}
 \mu_2 &= \int_{-\infty}^{\infty} (x - E(x))^2 f(x) dx \\
 &= \int_{-\infty}^{\infty} x^2 f(x) dx - 2E(x) \int_{-\infty}^{\infty} x f(x) dx + [E(x)]^2 \int_{-\infty}^{\infty} f(x) dx \\
 &= \int_{-\infty}^{\infty} x^2 f(x) dx - 2E(x)E(x) + [E(x)]^2 \times 1 \\
 &= \int_{-\infty}^{\infty} x^2 f(x) dx - [E(x)]^2 \\
 &= E(x^2) - [E(x)]^2 = \sigma^2
 \end{aligned}$$

其离散形式则有:

$$\text{Var}(x) = \sigma^2 = \sum p_i (x_i - \mu)^2$$

标准矩 (Standardized moment)

标准矩为标准化 (除以标准差) 后的中心矩, 第 n 阶中心矩 (standardized moment of degree n) 有:

$$\mu_n = E[(x - \mu)^n] = \int_{-\infty}^{\infty} (x - \mu)^n f(x) dx$$

已知标准差的 n 次方有:

$$\sigma^n = \left(\sqrt{E[(x - \mu)^2]} \right)^n = \left(E[(x - \mu)^2] \right)^{\frac{n}{2}}$$

此时, 第 n 阶标准矩有:

$$\tilde{\mu}_n = \frac{\mu_n}{\sigma^n} = \frac{E[(x - \mu)^n]}{\sigma^n}$$

由一阶中心矩为 0, 可知一阶标准矩 (first standardized moment) 也为 0。而二阶标准矩 (second standardized moment) 则有:

$$\tilde{\mu}_2 = \frac{\mu_2}{\sigma^2} = \frac{E[(x - \mu)^2]}{(E[(x - \mu)^2])^{2/2}} = 1$$

偏度 (skewness)

三阶标准矩 (third standardized moment) 为**偏度**:

$$\tilde{\mu}_3 = \frac{\mu_3}{\sigma^3} = \frac{E[(x - \mu)^3]}{(E[(x - \mu)^2])^{3/2}}$$

偏度分为两种：

- 负偏态或左偏态：左侧的尾部更长，分布的主体集中在右侧
- 正偏态或右偏态：右侧的尾部更长，分布的主体集中在左侧

峰度 (kurtosis)

四阶标准矩 (third standardized moment) 为**峰度**：

$$\tilde{\mu}_4 = \frac{\mu_4}{\sigma^4} = \frac{E[(x - \mu)^4]}{(E[(x - \mu)^2])^{4/2}}$$

定义**超值峰度 (excess kurtosis)**为峰度 -3 ，使得正态分布的峰度为 0：

$$\text{excess kurtosis} = \tilde{\mu}_4 - 3$$

- 如果超值峰度为正，即峰度值大于 3，称为高狭峰 (leptokurtic)
- 如果超值峰度为负，即峰度值小于 3，称为低阔峰 (platykurtic)

3.4 矩母函数

3.4.1 定义

矩母函数或称为矩生成函数 (Moment generating function, MGF) 或动差生成函数，顾名思义就是产生矩的函数。对于随机变量 X ，其矩生成函数定义为：

$$M_X(t) = \mathbb{E}(e^{tX})$$

离散形式下有：

$$\mathbb{E}[e^{tx}] = \sum e^{tx} P(x)$$

而在连续形势下有：

$$\mathbb{E}[e^{tx}] = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

定理 3.1. 将矩母函数进行 n 次求导，并令 $t = 0$ 则可得到 $\mathbb{E}(X^n)$

$$\mathbb{E}(X^n) = \left. \frac{d^n}{dt^n} M_X(t) \right|_{t=0}$$

证明. 对于 e^x 使用泰勒展开有:

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots + \frac{x^n}{n!}$$

那么 e^{tx} 的期望为:

$$\begin{aligned}\mathbb{E}[e^{tx}] &= \mathbb{E}\left[1 + tx + \frac{(tx)^2}{2!} + \frac{(tx)^3}{3!} + \cdots + \frac{(tx)^n}{n!}\right] \\ &= \mathbb{E}(1) + t\mathbb{E}(x) + \frac{t^2}{2!}\mathbb{E}(x^2) + \frac{t^3}{3!}\mathbb{E}(x^3) + \cdots + \frac{t^n}{n!}\mathbb{E}(x^n)\end{aligned}$$

对其求一阶导:

$$\begin{aligned}\frac{d}{dt}\mathbb{E}[e^{tx}] &= \frac{d}{dt}\left[\mathbb{E}(1) + t\mathbb{E}(x) + \frac{t^2}{2!}\mathbb{E}(x^2) + \frac{t^3}{3!}\mathbb{E}(x^3) + \cdots + \frac{t^n}{n!}\mathbb{E}(x^n)\right] \\ &= 0 + \mathbb{E}(x) + t\mathbb{E}(x^2) + \frac{t^2}{2}\mathbb{E}(x^3) + \cdots + \frac{t^{n-1}}{(n-1)!}\mathbb{E}(x^n) \\ &\quad (\text{代入 } t=0) \\ &= 0 + \mathbb{E}(x) + 0 + 0 + \cdots + 0 \\ &= \mathbb{E}(x)\end{aligned}$$

□

3.4.2 性质

对于标准正态分布 $N \sim (0, 1)$ 的矩母函数, 则有:

$$\begin{aligned}M_X(t) &= \mathbb{E}(e^{xt}) = \int e^{xt} \frac{1}{\sqrt{\pi}} e^{-\frac{1}{2}x^2} dx \\ &= \int \frac{1}{\sqrt{\pi}} e^{xt - \frac{1}{2}x^2} dx \\ &= \int \frac{1}{\sqrt{\pi}} e^{-\frac{1}{2}(x^2 - 2xt + t^2 - t^2)} dx \\ &= \int \frac{1}{\sqrt{\pi}} e^{-\frac{1}{2}(x-t)^2 + \frac{1}{2}t^2} dx \\ &= e^{\frac{1}{2}t^2} \int \frac{1}{\sqrt{\pi}} e^{-\frac{1}{2}(x-t)^2} dx \\ &= e^{\frac{1}{2}t^2}\end{aligned}$$

对于正态分布 $N \sim (\mu, \sigma)$ 的矩母函数，则有：

$$M_X(t) = \mathbb{E}(e^{xt}) = \int e^{xt} \frac{1}{\sigma\sqrt{\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx$$

此时代换 $z = \frac{x-\mu}{\sigma}$ ，即 $x = \sigma z + \mu$ ，并有 $dx = \sigma dz$ ：

$$\begin{aligned} M_X(t) &= \int e^{(\sigma z + \mu)t} \frac{1}{\sigma\sqrt{\pi}} e^{-\frac{1}{2}z^2} dx \\ &= e^{\mu t} \int e^{\sigma z t} \frac{1}{\sigma\sqrt{\pi}} e^{-\frac{1}{2}z^2} dx \\ &= e^{\mu t} \int \frac{1}{\sigma\sqrt{\pi}} e^{-\frac{1}{2}(z^2 - 2\sigma t z + (\sigma t)^2 - (\sigma t)^2)} dx \\ &= e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} \int \frac{1}{\sigma\sqrt{\pi}} e^{-\frac{1}{2}(z - \sigma t)^2} dx \\ &= e^{\mu t + \frac{1}{2}\sigma^2 t^2} \end{aligned}$$

4 假设检验 (Statistical hypothesis testing)

原假设 (H_0 , null hypothesis)，也称为零假设或虚无假设。而与原假设相反的假设称为备择假设 (H_a , alternative hypothesis)。假设检验的核心为反证法。在数学中，由于不能穷举所有可能性，因此无法通过举例的方式证明一个命题的正确性。但是可以通过举一个反例，来证明命题的错误。在掷骰子的例子中，在每次掷的过程相当于一次举例，假设进行了上万次的实验，即便实验结果均值为 3.5，也无法证明总体的均值为 3.5，因为无法穷举。

可以理解为原假设为希望拒绝的假设，或反证法中希望推翻的命题。我们先构造一个小概率事件作为原假设 (H_0)，并假设其正确。如样本均值等于某值，两个样本均值是否相等，样本中的不同组直接是否等概率发生，一般使用等式（小概率）作为原假设。如果抽样检验中小概率事件发生，则说明原假设的正确性值得怀疑。如此时假设实验的结果（样本）远大于或小于理论计算结果 3.5，即发生了小概率事件，那么就有理由相信举出了一个反例，这时就可以否定原命题（reject the null hypothesis）。而相反，如果原假设认为均值为 3.5，在实验的过程中结果大概率不会偏离这个理论值太多，可以认为我们并没办法举出反例。由于不能直接证明原命题为真，只能说 “We can not(fail to) reject the null hypothesis”，无法拒绝原命题。

在需要评估总体数据的时候，由于经常无法统计全部数据，需要从总体中抽出一部分样本进行评估。假设掷骰子一个骰子，其期望为 3.5，但假设掷骰子了 100 次，计算均值为 3.47，由于总体的理论值和样本呢的实验值可能存在偏差，误差永远存在，无法避免。那么是否可以认为么 3.47 “等于” 3.5？这时候就需要要界定一个显著水平 (α , significant level)，相当于设定一个等于的

阈值范围。即多小概率的事情发生，是 10% 还是 5% 的概率，使我们认为举出了一个反例，值得去怀疑原命题的正确性。当我们知道随机变量的分布时候，根据所进行的检验，我们可以根据计算出的统计量 (test statistic)，由于分布已知，统计量对应了一个 **p 值 (p-value)**，即小概率（极端）事件发生的概率，因此在图形上表示为统计量向两侧延申的线下区域。如果这个概率足够低，如小于 $\alpha = 5\%$ ，那么就有理由拒绝原假设。

用 $1 - \alpha$ 显著水平 ($1 - \alpha$)，得到值称为**置信水平 (confidence level)** (概率大小)。置信水平越大，对应的置信区间也越大 (随机变量范围)。此时有置信水平为 $1 - \alpha$ ，假设置信区间为 (a, b) ，那么有 $P(a < \text{随机变量} < b) = 1 - \alpha$ 。对于双侧检验，有置信水平为 $1 - \alpha$ (概率大小)，两侧拒绝域分别为 $\alpha/2$ 。对于单侧检验，则有单侧拒绝域大小为 α 。

5 Chi-square distribution

假设有随机变量 X 服从标准正态分布，即有 $X \sim N(0, 1)$ ，此时有随机变量 $Q_1 = X^2$ ，则有随机变量 Q_1 服从卡方分布 (χ^2 -distribution)，由于此时只有一个随机变量，因此卡方分布自由度 (degree of freedom) 为 1，即 $Q_1 \sim \chi^2(1)$ 。如随机变量 $Q_2 = X_1^2 + X_2^2$ ，且 X_1 与 X_2 同时服从标准正态分布。则此时 Q_2 服从自由度为 2 的卡方分布，即 $Q_2 \sim \chi^2(2)$ 。

Goodness of fit

Pearson's chi-squared test

$$\chi^2 = \sum_i^n \frac{(O_i - E_i)^2}{E_i}$$

- O_i the number of observations of type i
- E_i the expected(theoretical) number of type i

6 Probability vs Likelihood

6.1 Probability

$P(\text{data} \mid \text{distribution}) = \text{area under curve}$

$P(\text{weight between 32g and 34g} \mid \text{mean} = 32 \text{ and standard deviation} = 2.5) = 0.29$

$$P(\text{weight} > 34\text{g} \mid \text{mean} = 32 \text{ and standard deviation} = 2.5) = 0.21$$

6.2 Likelihood

$$L(\text{distribution} \mid \text{data}) = \text{value of the curve (y)}$$

$$L(\text{mean} = 32 \text{ and standard deviation} = 2.5 \mid \text{mouse weights } 34\text{g}) = 0.12$$

$$L(\text{mean} = 34 \text{ and standard deviation} = 2.5 \mid \text{mouse weights } 34\text{g}) = 0.21$$

在调整了分布的 mean 之后, likelihood 最大, 在 mean=34 sigma=2.5 的正态分布中, 抽中一只 34g 的老鼠的概率最大

6.3 Maximum likelihood

测量了数只老鼠的重量, 尝试找到其分布, maximizes the likelihood 找到最大化所有观察重量 likelihood 的分布, 找到 mean 和 standard deviation

7 Time series

Autoregressive (AR) model

vector autoregressive model (VAR) (more than one random variable)

Moving-average (MA) model

ARMA / ARIMA

autoregressive-moving-average (ARMA) / autoregressive integrated moving average (ARIMA)

TODO: Autocorrelation (serial correlation) - $cov(u_i, u_j) \neq 0$, for $i \neq j$ - some other estimator will have a lower variance, no longer best estimate - Unit root processes, autoregressive processes, and moving average processes are specific forms of processes with autocorrelation.

Autocorrelation and Partial Autocorrelation

The coefficient of correlation between two values in a time series is called the autocorrelation function (ACF), $Corr(x_t, x_{t-k}), k = 1, 2, 3, \dots$

$$\rho_k = \frac{\text{cov}(x_t, x_{t-k})}{\sigma_{x_t} \sigma_{x_{t-k}}} = \frac{\gamma_k}{\gamma_0}$$

$$\gamma_k = \sum_{t=1}^{T-k} (x_t - \bar{x})(x_{t+k} - \bar{x}) / T$$

$$\gamma_0 = \sum_{t=1}^T (x_t - \bar{x})^2 / T$$

Durbin-Watson test

- H0: $\rho = 0$, no autocorrelation / serial correlation in residual - H1: $\rho \neq 0$, autocorrelation in residual, follow first order autoregressive process

Test statistic - residual at lag 1, $\epsilon_t = \rho\epsilon_{t-1} + u_t$ - $DW = \frac{\sum_{t=2}^T (\epsilon_t - \epsilon_{t-1})^2}{\sum_{t=1}^T \epsilon_t^2}$

2 -> no autocorrelation 0-2 -> positive autocorrelation 2-4 -> negative autocorrelation

Ljung-Box test

Test the null hypothesis that a series of residuals exhibits no autocorrelation for a fixed number of lags L. (See Box & Pierce 1970, Q test)

- H0: No residual autocorrelation - H1: There is residual autocorrelation

Test statistic

$$Q = T(T+2) \sum_{k=1}^L \frac{\rho(k)^2}{T-k} > \chi_L^2$$

- Q is chi-square with L degrees of freedom

Dickey-Fuller test H0: there is unit root, $\delta = \rho - 1 = 0$, no stationary, random walk H1: stationary, mean and variance do not change over time

A simple AR(1) model $y_t = \alpha + \rho y_{t-1} + u_t$, then we have $\Delta y_t = \alpha + (\rho - 1)y_{t-1} + u_t = \alpha + \delta y_{t-1} + u_t$,

Augmented Dickey-Fuller

H0: there is unit root, $\delta = 0$ H1: stationary, $\delta < 0$

ADF test: $\Delta y_t = \alpha + \delta y_{t-1} + \beta_1 \Delta y_{t-1} + \dots + \beta_p \Delta y_{t-p} + u_t$

AR(1) model: $\Delta y_t = \alpha + \delta y_{t-1} + u_t$ AR(2) model: $\Delta y_t = \alpha + \delta y_{t-1} + \beta \Delta y_{t-1} + u_t$

Test statistics: (negative, more negative \rightarrow reject H_0)

$$- DF_{\delta} = \frac{\hat{\delta}}{SE(\hat{\delta})}$$